

< Squared Error criterion and the method of least squares 7/12 >

Autonomous system 에서 자신의 현재 state 는 필수적으로 알아야 함

↳ state estimation 으로 접근

센서에는 노이즈가 있으므로 이를 최소화하는 optimal한 방법을 찾아야 한다

* Least - squares

measurement models 를 $y_n = x + v_n$ 으로 설정

Actual value

measurement noise

squared error : $e_n^2 = (y_n - x)^2 = v_n^2$

이 n개의 observations의 제곱 합이 최소가 되도록 하는 x_{LS} 를 찾는다

$$x_{LS} = \operatorname{argmin}_x (e_1^2 + e_2^2 + \dots + e_n^2) = L_{LS}(x)$$

$$\vec{e} = \begin{bmatrix} e_1 \\ e_2 \\ \vdots \\ e_n \end{bmatrix} = \vec{y} - \overset{\text{Jacobian}}{\underset{\text{scalar}}{H}} x = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} - \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} x$$

$$L_{LS}(x) = e_1^2 + e_2^2 + \dots + e_n^2 = \vec{e}^T \vec{e} \text{ (dot product)}$$

$$= (\vec{y} - Hx)^T (\vec{y} - Hx)$$

노이즈가 최소화되도록 하는 스칼라 x를

$$= \vec{y}^T \vec{y} - \vec{y}^T Hx - x^T H^T \vec{y} + x^T H^T Hx$$

찾으면 그것이 정답.

$L(x)$ 를 최소화하기 위해 극소를 찾는다.

$$L(x) = \underbrace{y^T y}_{\text{측정되어 고정된 상수항}} - x^T H^T y - y^T H x + x^T H^T H x$$

$$\frac{\partial L}{\partial x} = -(y^T H)^T - y^T H + 2x^T H^T H$$

$y^T H$ 는 전과같이 상수이므로 전체와 같다

$$= -2y^T H + 2x^T H^T H = 0$$

$$2H^T H (x - \underbrace{(H^T H)^{-1} y^T H}_{\text{0}}) = 0$$

$$x_{LS} = (H^T H)^{-1} y^T H = (H^T H)^{-1} (H^T y)^T = \underbrace{(H^T H)^{-1} H^T y}$$

$\hookrightarrow (H^T H)^{-1}$ 부분을 포함하므로 x_{LS} 가 존재하기 위해서는 $H^T H$ 의 역행사가 존재해야함

* Jacobian matrix (H)

① Linear system

$y = Hx + \text{noise}$ 형태로 일반적으로 나타냄

< 차가 위치, 속도의 2가지 변수를 측정할 때 >

$x = \begin{bmatrix} p \\ v \end{bmatrix}$, 센서가 위치의 한가지 데이터만 준다면 $H = [1 \ 0] \rightarrow [1 \ 0] \begin{bmatrix} p \\ v \end{bmatrix}$

센서가 위치와 속도를 모두 측정할 때 $\rightarrow H = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} p \\ v \end{bmatrix}$

$\rightarrow$ 자코비안 행렬의 크기는 (센서의 측정 변수 개수) $\times$ (알아내고자 하는 상태변수의 개수)

센서의 측정 횟수를 늘려 누적된 데이터를 사용하면 행은 (측정 변수 개수) $\times$ (측정 횟수)가 된다.
따라서 전체 측정 데이터의 개수로 보는 것이 정확하다.

② non-linear system

예를 들어, 드론의 위치 좌표를 알아내는 것이 목적인데 센서는 기지국으로부터의 거리와 그 방향각만을 측정하는 상황을 가정.

(1)

$$\text{측정 모델 함수 } h(x) = \begin{bmatrix} r \\ \theta \end{bmatrix} = \begin{bmatrix} \sqrt{p_x^2 + p_y^2} \\ \sim \end{bmatrix}$$

이때 H 는 $\begin{bmatrix} \frac{\partial r}{\partial p_x} & \frac{\partial r}{\partial p_y} \\ \frac{\partial \theta}{\partial p_x} & \frac{\partial \theta}{\partial p_y} \end{bmatrix}$ 로 도출.

* $H^T H$ 의 역행렬 존재 조건

m 개의 측정 데이터와 n 개의 unknown parameters에 대해

$$H \in \mathbb{R}^{m \times n} \quad H^T H \in \mathbb{R}^{n \times n}$$

$\text{rank}(H^T H) = \text{rank}(H)$ 이므로 $H^T H$ 가 full rank가 되려면 $\text{rank}(H) = n$ 이어야 함

따라서 $m \geq n$ 으로 상태변수의 개수가 측정 데이터의 수보다 적어야 역행렬이 존재한다

* Weighted Least Squares

the general linear measurement model

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = H \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} + \begin{bmatrix} v_1 \\ \vdots \\ v_m \end{bmatrix}$$

$$y = Hx + v$$

일반적인 least squares에서는 각 noise 항이 모두 동일한 분산을 가진다고 가정함

$$1) \text{ 분산 } \text{Var}(X) = E[(X - \mu)^2]$$

하나의 동일한 센서에서 측정된 noise v_n 의 평균 $\mu = 0$

$$\rightarrow \text{Var}(X) = E[(v - 0)^2] = E[v^2]$$

$$E[v_i^2] = \sigma^2 \quad (i = 1, 2, \dots, m)$$

$$2) vv^T = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} v_1^2 & \dots & v_1 v_2 & \dots & v_1 v_n \\ & v_2^2 & & & \\ & & \ddots & & \\ & & & v_n^2 & \end{bmatrix}$$

$$E[vv^T] = \begin{bmatrix} E[v_1^2] & \dots & E[v_1 v_2] & \dots & E[v_1 v_n] \\ \vdots & E[v_2^2] & & & \vdots \\ \vdots & & \ddots & & \vdots \\ \vdots & & & E[v_n^2] & \end{bmatrix} = R$$

모든 센서가 서로에 대해 independent

$E[v_n] = 0 = \mu$ 로 값이 전부 0.

diagonal 모두 σ^2

* 단일 센서는 하나의 상태 변수만을 동일한 성능으로 측정한다. 만약 한 센서가 2개의 상태 변수를 한번에 측정할 수 있다면 그건 서로 다른 2개의 센서로 보아야 한다.

* i.i.d 가정을 같은 센서로 감들은 측정했을 때에만 성립함. 즉 하나의 상태 변수만을 측정하는 동일한 단일 센서에 대해서만 regular least squares를 적용할 수 있고, 2개 이상의 상태 변수 분석을 위해 여러 센서를 사용할 때는 weighted LS를 써야 한다.

* About weighted LS

각 noise 항이 independent 하지만, 다른 분산을 가진다고 가정

$$E[v_i^2] = \sigma_i^2 \quad (i=1, \dots, m) : m\text{개의 센서}$$

$$R = E[vv^T] = \begin{bmatrix} \sigma_1^2 & & 0 \\ & \ddots & \\ 0 & & \sigma_m^2 \end{bmatrix}$$

$$L_{WLS}(x) = e^T R^{-1} e$$

$$= \frac{e_1^2}{\sigma_1^2} + \frac{e_2^2}{\sigma_2^2} + \dots + \frac{e_m^2}{\sigma_m^2}$$

측정값. 맞다 내리자 하는 값.

$$\text{where } e = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} - H \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

Minimizing $L_{WLS}(x)$

$$(y^T R^{-1} H x)^T$$

$$L_{WLS} = (y - Hx)^T R^{-1} (y - Hx)$$

$$= y^T R^{-1} y - y^T R^{-1} H x - x^T H^T R^{-1} y + x^T H^T R^{-1} H x$$

$$\frac{\partial L}{\partial x} = -2y^T R^{-1} H + 2x^T H^T R^{-1} H = 0$$

$$\rightarrow H^T R^{-1} H x_{WLS} = H^T R^{-1} y$$

The weighted normal equations

$$\therefore x_{WLS} = (H^T R^{-1} H)^{-1} H^T R^{-1} y$$

★ λ 에 큰 값의 데이터를 아목덜거나 배치하더라도 측정 오차 σ 를 통해 제곱비만 행렬 R 은
크게 작게 설정한다면 동일한 상태변수끼리의 noise를 모두 고려한 오차가 가장 작은 x 가
드러난다. H 가 레이어를 매칭하는 주소록 역할.

< Recursive Least squares 7/12 >

전에 했던 Least squares는 batch, 데이터를 2아서 한번에 $\hat{x}$ 를 찾는다.



실시간으로 데이터를 받아 $\hat{x}$ 를 업데이트 하는 것이 Recursive LS.

time $k-1$ 에서의 unknown parameters를 $\hat{x}_{k-1}$ 라 하자

$$\text{time } k \text{ 에서 } y_k = H_k \hat{x} + v_k$$

→ linear recursive update

$$\hat{x}_k = \hat{x}_{k-1} + K_k (y_k - H_k \hat{x}_{k-1})$$

현재가 과거의 데이터에 대해 얼마나 잘 맞추는가. 얼마나 정확한가.

Gain matrix

: Innovation의 가중치.

절대적인 값

$$L_{RLS} = E[(\hat{x}_k - \hat{x}_k)^2] = \sigma_k^2$$

추정기의 측정값

n 개의 unknown parameters에 대해

$$L_{RLS} = E[(x_{1k} - \hat{x}_{1k})^2 + (x_{2k} - \hat{x}_{2k})^2 + \dots + (x_{nk} - \hat{x}_{nk})^2]$$

$$= \text{Trace}(P_k)$$

Estimator covariance

추정기의 공분산. 센서와 관측값이 자신이 도출해낸 $\hat{x}_k$ 를 얼마나 못 믿는지를 나타냄.

$(x_k - \hat{x}_k)$ 스스로의 외적에 기대값을 씌운 행렬

Using linear recursive formulation, we can express covariance as a function of k

$$P_k = (I - K_k H_k) P_{k-1} (I - K_k H_k)^T + K_k R_k K_k^T$$

P_k 는 $K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1}$ 일 때 minimized



이때 P_k 를 다시 적으면

P_k 가 최솟값 될 때, 참값과 측정값의

차이가 가장 작아 신뢰도가 올라가기 때문

$$P_k = P_{k-1} - K_k H_k P_{k-1}$$

$$= \underline{(I - K_k H_k) P_{k-1}}$$

→ 시간이 지남수록 P_k 가 계속 작아져나가는 중이다.

k 도 시간이 지남수록 센서값과 자신의 값은 신뢰하게

되므로 그 감소량이 줄어든다.

* RLS의 Algorithm

① Initialize the estimator.

(0 혹은 다룰기)

$$\hat{x}_0 = E[x]$$

→ 초기 $\hat{x}_0$ 값은 아무 숫자나 잡거나

0을 그대로 넣고 쓴다.

$$P_0 = E[(x - \hat{x}_0)(x - \hat{x}_0)^T]$$

② set up the measurement model, defining Jacobian and the measurement covariance matrix

$$y_k = H_k x + v_k$$

③ update the estimate of $\hat{x}_k$ and the covariance P_k using

$$K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1} \rightarrow \text{기본식으로는 } \frac{P}{P+R} \text{ 형태.}$$

$$\hat{x}_k = \hat{x}_{k-1} + K_k (y_k - H_k \hat{x}_{k-1})$$

$P \gg R$ 이면 k 가 1에 가까워져 전적으로 센서를 믿음

$$P_k = (I - K_k H_k) P_{k-1}$$

센서 노이즈
(분산)

$P \ll R$ 이면 센서를 무시하고 $\hat{x}_{k-1}$ 을 고정. ($k \rightarrow \infty$)

* R_k 와 P_k 는 시간이 지남수록 계속 줄어들어 결국 0으로 수렴한다.

R_k 는 센서보다 자신의 값에 의존하게 되어 $\hat{x}_k \approx \hat{x}_{k-1}$ 가 되기에 0으로 수렴한다.
(이미 알고 있는 전 단계)

P_k 는 처음에 불확실성이 100% 이다가 단계를 거칠수록 $P_k = P_{k-1} - K_k H_k P_{k-1}$ 에 의해 계속 작아져나감 (shrink) 나중에는 알고리즘과 계산량에 대한 불확실성이 0이 된다.

* H_k 는 linear / non-linear 에 따라 고정되거나 변화한다.

선형 시스템이면 H 는 고정된 값으로 채워지지만, 비선형일 때는 H 값에 상대 변수가 들어감 step을 지날 때마다 새로 업데이트 해야한다.

< P_k, K_k , minimized P_k 9/13 >

Estimator: $\hat{x}_k = \hat{x}_{k-1} + K_k(y_k - H_k \hat{x}_{k-1})$

sensor: $y_k = H_k x_k + v_k$

1)

Estimator의 추정 오차를 따라 하면

$$e_k = x_k - \hat{x}_k$$

$$= x_k - (\hat{x}_{k-1} + K_k(y_k - H_k \hat{x}_{k-1}))$$

$$= x_k - (\hat{x}_{k-1} + K_k(H_k x_k - H_k \hat{x}_{k-1} + v_k))$$

$$= (x_k - \hat{x}_{k-1}) - K_k H_k (x_k - \hat{x}_{k-1}) - K_k v_k$$

x_k 항값으로 항상 일정 $\rightarrow x_k - \hat{x}_{k-1} = e_{k-1}$ 이 의미.

$$= e_{k-1} - K_k H_k e_{k-1} - K_k v_k$$

$$= (I - K_k H_k) e_{k-1} - K_k v_k$$

2)

$$P_k = E[(x - \hat{x}_k)(x - \hat{x}_k)^T]$$

$$= E[e_k e_k^T]$$

$$= E[\{(I - K_k H_k) e_{k-1} - K_k v_k\} \{(I - K_k H_k) e_{k-1} - K_k v_k\}^T]$$

$\downarrow$ e_{k-1} 와 v_k 는 독립

$$P_k = (I - K_k H_k) E[e_{k-1} e_{k-1}^T] (I - K_k H_k)^T + K_k E[v_k v_k^T] K_k^T$$

$$= (I - K_k H_k) P_{k-1} (I - K_k H_k)^T + K_k R_k K_k^T$$

~~~~~

3)

$$P_k = P_{k-1} - K_k H_k P_{k-1} - P_{k-1} H_k^T K_k^T + K_k H_k P_{k-1} H_k^T K_k^T + K_k R_k K_k^T$$

$$\frac{\partial (\text{Trace}(P_k))}{\partial K_k} = -2P_{k-1} H_k^T + 2K_k (H_k P_{k-1} H_k^T + R_k) = 0$$

$\frac{\partial}{\partial K_k}$ ?  $\rightarrow P_k$ 를 나타내는 식에서 유일한 변수,  $\hat{x}_{k-1}$ 은 지나간 값이므로  $\frac{\partial}{\partial \hat{x}_{k-1}}$  의미없음. 따라서

$$K_k (H_k P_{k-1} H_k^T + R_k) = P_{k-1} H_k^T$$

$\frac{\partial K_k}{\partial K_k}$ 를 사용한다.

$$K_k = P_{k-1} H_k^T (H_k P_{k-1} H_k^T + R_k)^{-1}$$

Kalman Gain

$\therefore$  처음 step에 값을 넣지 않고 알아서 알고리즘에 의해 계산됨. 센서를 더 믿으면  $H$ 에 가까워지고, Estimator

자신을 믿으면 0에 가까워짐.

4)

$$P_k = P_{k-1} - K_k H_k P_{k-1} - P_{k-1} H_k^T K_k^T + K_k (H_k P_{k-1} H_k^T + R_k) K_k^T$$

$$K_k^{-1} P_{k-1} H_k^T$$

$$= P_{k-1} - K_k H_k P_{k-1} - P_{k-1} H_k^T K_k^T + P_{k-1} H_k^T K_k^T$$

$$= P_{k-1} - K_k H_k P_{k-1}$$

$$P_k = (I - K_k H_k) P_{k-1}$$

(독립)

$\rightarrow R_k$ 의 경우, 센서들끼리 영향을 주지 않는다면 비대각성분이 0임.

하지만  $P_k$ 의 경우는 독립 가정이 불가능함. 처음 step에서 독립으로

가정하더라도 시간이 지나면서 변수들끼리의 관계가 서로 밀려나 지는 잘못

측정했다면 그 다음 step의 지라 그 모든 추정이 잘못되기 때문.

## < Least Squares and the method of Maximum Likelihood 7/13 >

Least Squares 에서 오차를 최소가 되도록 만들기 위해 2개 '샘플'을 사용하는가?

why not 3샘플? 4샘플?

\* measurement model을  $y = x + v$ 로 가정

$$v \sim \mathcal{N}(0, \sigma^2)$$

Normal distribution (정규분포)

or

Gaussian distribution

$P(y|x) = \mathcal{N}(x, \sigma^2)$  : 센서에 측정되어 나오는 값은 주로 중심으로 오차가 발생하기 때문에 평균이  $x$ 로 변함

$$\mathcal{N}(z; \mu, \sigma^2) = \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{(z-\mu)^2}{2\sigma^2}} \text{ 에서}$$

$$P(y|x) = \mathcal{N}(y; x, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(y-x)^2}{2\sigma^2}}$$

multiple measurements 에 대해

$$P(y_1|x) = \mathcal{N}(y_1; x, \sigma^2) \times \mathcal{N}(y_2; x, \sigma^2) \times \dots \times \mathcal{N}(y_m; x, \sigma^2)$$

$$= \frac{1}{\sqrt{(2\pi)^m \sigma^{2m}}} \exp \left( -\frac{\sum_{i=1}^m (y_i - x)^2}{2\sigma^2} \right)$$

## \* Maximal likelihood estimate (MLE)

$$\hat{\lambda}_{MLE} = \underset{\lambda}{\operatorname{argmax}} P(y|\lambda)$$

↓ 계산의 편의성을 위해

$$\hat{\lambda}_{MLE} = \underset{\lambda}{\operatorname{argmax}} \log P(y|\lambda)$$

MLE는 확률적 접근

LS는 2차를 최소로 만드는 접근법이라면,

MLE는 측정된 데이터 값이 나올 확률을 가장

크게 만드는 기준,  $\lambda$  (값값)이 존재할 것이 라고

보고 접근. 즉,  $P(y|\lambda)$ 를 최대로 만드는

$\lambda$ 를 찾는 방식이다.

$$\log P(y|\lambda) = -\frac{1}{2\sigma^2} ((y_1 - \lambda)^2 + (y_2 - \lambda)^2 + \dots + (y_m - \lambda)^2) + C$$

여기서  $\underset{\lambda}{\operatorname{argmax}} f(\lambda) = \underset{\lambda}{\operatorname{argmin}} (-f(\lambda))$  라 같으므로

$$\hat{\lambda}_{MLE} = \underset{\lambda}{\operatorname{argmin}} -(\log P(y|\lambda))$$

$$= \underset{\lambda}{\operatorname{argmin}} \frac{1}{2\sigma^2} ((y_1 - \lambda)^2 + \dots + (y_m - \lambda)^2)$$

여기서 각 measurements가 서로 다른 variance를 가진다고 하면

$$\hat{\lambda}_{MLE} = \underset{\lambda}{\operatorname{argmin}} \frac{1}{2} \left\{ \left( \frac{y_1 - \lambda}{\sigma_1} \right)^2 + \dots + \left( \frac{y_m - \lambda}{\sigma_m} \right)^2 \right\}$$

하나 이쁘게 outlier  
발생시 (inter) 값

outlier 지우는 작업 필수

$$\hat{\lambda}_{MLE} = \hat{\lambda}_{LS} = \hat{\lambda}_{WLS} = \underset{\lambda}{\operatorname{argmin}} L_{LS}(\lambda) = \underset{\lambda}{\operatorname{argmax}} L_{MLE}(\lambda)$$

## \* Center Limit Theorem (중심 극한 정리)

: independent random variables가 더해지면 그들은 정규분포를 따르는 방향으로 간다.

하나의 센서가 측정값을 내기까지 다양한 요인에 의해 영향을 받음

측정값은 정규분포

Least squares를 쓰는 이유

① 중심 극한 정리에 따라 2차원은 정규분포를 따르므로 최소 제곱법

② Gaussian noise에 대해 MLE와 동등한 접근법이다.  
(타당한 접근법이다)