

< Going nonlinear - The extended kalman filter 7/14 >

현실에서 linear system은 존재하지 않는다. 따라서 nonlinear system은 다뤄는 EKF를 사용해야함.

* Taylor expansion

$$f(x) = f(a) + \left. \frac{\partial f(x)}{\partial x} \right|_{x=a} (x-a) + \frac{1}{2!} \left. \frac{\partial^2 f(x)}{\partial x^2} \right|_{x=a} (x-a)^2 + \frac{1}{3!} \left. \frac{\partial^3 f(x)}{\partial x^3} \right|_{x=a} (x-a)^3 + \dots$$

비선형 $f(x)$ 를 linearization을 통해 선형으로 변형시키기 위해 first-order만 남김.

$$\hookrightarrow f(x) \approx f(a) + \left. \frac{\partial f(x)}{\partial x} \right|_{x=a} (x-a)$$

* Linearized Motion Model

$$x_k = f_{k-1}(x_{k-1}, u_{k-1}, w_{k-1})$$

F_{k-1}

$$\approx f_{k-1}(\hat{x}_{k-1}, u_{k-1}, 0) + \left. \frac{\partial f_{k-1}}{\partial x_{k-1}} \right|_{\hat{x}_{k-1}, u_{k-1}, 0} (x_{k-1} - \hat{x}_{k-1})$$

테일러 전개는 위한 기준점은

0으로 잡았다는 의미. 실제 w_{k-1} 은

0이 아니지만 가장 확률이 높은 개념을

채택해 0이 된다.

$$+ \left. \frac{\partial f_{k-1}}{\partial w_{k-1}} \right|_{\hat{x}_{k-1}, u_{k-1}, 0} (w_{k-1}).$$

L_{k-1}

* u_{k-1} 은 알고리즘이 controller에 내린 명령으로 그자가 존재하지 않는다. 따라서 상수로 취급되어

$$\frac{\partial f_{k-1}}{\partial u_{k-1}} = 0, \text{ 제어항은 사라지고, } F_{k-1} \text{과 } L_{k-1} \text{만 남는다.}$$

* Linearized measurement model

$$y_k = h_k(x_k, v_k)$$

$$\approx h_k(\check{x}_k, 0) + \underbrace{\left. \frac{\partial h_k}{\partial x_k} \right|_{\check{x}_k, 0}}_{H_k} (x_k - \check{x}_k) + \underbrace{\left. \frac{\partial h_k}{\partial v_k} \right|_{\check{x}_k, 0}}_{M_k} (v_k - 0)$$

* Jacobian matrices.

선형화된 f_{k-1} 과 h_k 에서 F_{k-1} , I_{k-1} , H_k , M_k 는 모두 자코비안 행렬이다.

$$\frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f}{\partial x_1} & \dots & \frac{\partial f}{\partial x_n} \end{bmatrix} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \dots & \frac{\partial f_1}{\partial x_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial f_m}{\partial x_1} & \dots & \frac{\partial f_m}{\partial x_n} \end{bmatrix}$$

→ input dimension에 대한 output function이 얼마나 빠르게 변화하는지를 나타냄

ex)

$$f(x) = \begin{bmatrix} f_1 \\ f_2 \end{bmatrix} = \begin{bmatrix} x_1 + x_2 \\ x_1^2 \end{bmatrix} \rightarrow \frac{\partial f}{\partial x} = \begin{bmatrix} \frac{\partial f_1}{\partial x_1} & \frac{\partial f_1}{\partial x_2} \\ \frac{\partial f_2}{\partial x_1} & \frac{\partial f_2}{\partial x_2} \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 2x_1 & 0 \end{bmatrix}$$

다음 step의 x_1 (pointing to f_1)
다음 step의 x_2 (pointing to f_2)

* EKF equations

① Linearized motion model

$$\mathbf{x}_k = f_{k-1}(\hat{\mathbf{x}}_{k-1}, u_{k-1}, 0) + F_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + L_{k-1} w_{k-1}$$

② Linearized measurement model

$$\mathbf{y}_k = H_k(\mathbf{x}_k - \check{\mathbf{x}}_k) + M_k v_k$$

③ Prediction

$$\check{\mathbf{x}}_k = f_{k-1}(\hat{\mathbf{x}}_{k-1}, u_{k-1}, 0)$$

w_{k-1} 이 매우 작아 0인 이유. 항상은 w_{k-1} 이 맞는데 필터는 항상이 존재한 것이라 믿는 평균지점을 $\check{\mathbf{x}}_k$ (motion model)로 내놓는다. 이렇게 사라진 2차항은 $\check{\mathbf{P}}_k$ 에서 Q_{k-1} 과 L_{k-1} 로 계속 반영되고 있음.

$$\check{\mathbf{P}}_k = F_{k-1} \hat{\mathbf{P}}_{k-1} F_{k-1}^T + \underbrace{L_{k-1} Q_{k-1} L_{k-1}^T}$$

④ Optimal gain


$$\mathbf{K}_k = \check{\mathbf{P}}_k H_k^T (H_k \check{\mathbf{P}}_k H_k^T + M_k R_k M_k^T)^{-1}$$

⑤ Correction

$$\hat{\mathbf{x}}_k = \check{\mathbf{x}}_k + \mathbf{K}_k (\mathbf{y}_k - h_k(\check{\mathbf{x}}_k, 0))$$

$$\hat{\mathbf{P}}_k = (I - \mathbf{K}_k H_k) \check{\mathbf{P}}_k$$

example)



상태변수 x 은 $\begin{bmatrix} P \\ \dot{P} \end{bmatrix}$ 로 정의

$$P_k = P_{k-1} + \Delta t \dot{P}_{k-1}$$

$$\dot{P}_k = \dot{P}_{k-1} + \Delta t \ddot{P}_{k-1}$$

제어변수 $u = \ddot{P}$

1) Motion model

$$x_k = f_{k-1}(\hat{x}_{k-1}, u_{k-1}, w_{k-1})$$

$$= F_{k-1} \hat{x}_{k-1} + G_{k-1} u_{k-1} + I_{k-1} w_{k-1}$$

$$= \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix} \hat{x}_{k-1} + \begin{bmatrix} 0 \\ \Delta t \end{bmatrix} u_{k-1} + w_{k-1}$$

일반적인 경우에 비선형에 대한 model은 measurement

처럼 정형화되지 않는 형태로 나뉘지만, 현재 상황에서

motion model은 이미 linear 이므로 linear Kalman

filter의 식을 그대로 사용할 수 있다.

2) Measurement Model

$$y_k = \phi_k = h(p_k, v_k)$$

$$= \tan^{-1} \left(\frac{S}{D - P_k} \right) + v_k$$

* Noise densities

$$Q = \begin{bmatrix} \sigma_{w1}^2 & \sigma_{w1w2} \\ \sigma_{w2w1} & \sigma_{w2}^2 \end{bmatrix}$$

$$v_k \sim \mathcal{N}(0, 0.01) \quad w_k \sim \mathcal{N}(0, (0.1) I_{2 \times 2})$$

보통 x_1 과 x_2 에 작용하는 noise는 독립이라 가정한다.

3) Jacobians

$$F_{k-1} = \frac{\partial f}{\partial \mathbf{x}_{k-1}} \bigg|_{\hat{\mathbf{x}}_{k-1}, u_{k-1,0}} = \begin{bmatrix} 1 & \Delta t \\ 0 & 1 \end{bmatrix}$$

$$L_{k-1} = \frac{\partial f}{\partial \mathbf{w}_{k-1}} \bigg|_{\hat{\mathbf{x}}_{k-1}, u_{k-1,0}} = \begin{pmatrix} \mathbf{I}_{2 \times 2} \end{pmatrix} \text{ additive noise 가정.}$$

$$H_k = \frac{\partial h}{\partial \mathbf{x}_k} \bigg|_{\hat{\mathbf{x}}_{k,0}} = \begin{bmatrix} s & 0 \\ \frac{s}{(D - \hat{r}_k)^2 + s^2} & 0 \end{bmatrix}$$

$$M_k = \frac{\partial h}{\partial \mathbf{v}_k} \bigg|_{\hat{\mathbf{x}}_{k,0}} = \begin{pmatrix} 1 \end{pmatrix} \text{ additive noise 가정}$$

4) Data

$\hat{\mathbf{p}}_k$

$$\hat{\mathbf{x}}_0 \sim \mathcal{N} \left(\begin{bmatrix} 0 \\ 5 \end{bmatrix}, \begin{bmatrix} 0.01 & 0 \\ 0 & 1 \end{bmatrix} \right)$$

$$\Delta t = 0.5 (s)$$

$$u_0 = -2 (m/s^2)$$

$$s = 20 (m)$$

$$y_1 = \pi/6 (rad)$$

$$D = 40 (m)$$

★ Additive noise 와 분산

noise의 원인은 상태변수 외부의 영향으로 잡은 noise는 하나임 (w_n) 그러나 이 noise의 영향이 L 에 쪼개져 들어가야 하기 때문에 identity가 아니라 주적으로 복잡하게 표현된 것이다. 그러나 Q 는 $Q = \sigma_n^2$ 로 단순하게 표현가능.



이런 간단하게 나타내는 도구가 additive noise이다. noise (w_p, w_v)가 각 상태변수에 따른 들어간다고 하면 $L = \mathbf{I}$ 임. 그러나 각 위치, 속도 noise는 독립이므로 하나의 원인으로부터 기인했으므로 모든 상관관계를 Q 에서 잘 떼어 나타내야 함. 독립이라면 diagonal만 넣는 것이다. 따라서 Q 를 확실히 만들어 놓기 위해 해답에 매우 중요함.

5) Prediction

$$\check{x}_1 = f_0(\hat{x}_0, u_0, 0)$$

$$\begin{bmatrix} \check{p}_1 \\ \check{p}_1 \end{bmatrix} = \begin{bmatrix} 1 & 0.5 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0 \\ 5 \end{bmatrix} + \begin{bmatrix} 0 \\ 1.5 \end{bmatrix} (-2) = \begin{bmatrix} 2.5 \\ 4 \end{bmatrix}$$

$$\check{P}_1 = F_0 \hat{P}_0 F_0^T + L_0 Q_0 L_0^T$$

$$= \begin{bmatrix} 1 & 0.5 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0.01 & 0 \\ 0 & 0.1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0.5 & 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 0.1 & 0 \\ 0 & 0.1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

$$= \begin{bmatrix} 0.36 & 0.5 \\ 0.5 & 1.1 \end{bmatrix}$$

6) Correction

$$k_1 = \check{P}_1 H_1^T (H_1 \check{P}_1 H_1^T + M_1 R_1 M_1^T)^{-1}$$

$$= \begin{bmatrix} 0.36 & 0.5 \\ 0.5 & 1.1 \end{bmatrix} \begin{bmatrix} 0.01 \\ 0 \end{bmatrix} \left(\begin{bmatrix} 0.01 & 0 \end{bmatrix} \begin{bmatrix} 0.36 & 0.5 \\ 0.5 & 1.1 \end{bmatrix} \begin{bmatrix} 0.01 \\ 0 \end{bmatrix} + (1)(2.0)(1) \right)^{-1}$$

$$= \begin{bmatrix} 0.40 \\ 0.55 \end{bmatrix}$$

$$\hat{x}_1 = \check{x}_1 + k_1 (y_1 - h_1(\check{x}_1, 0))$$

$$\begin{bmatrix} \hat{p}_1 \\ \hat{p}_1 \end{bmatrix} = \begin{bmatrix} 2.5 \\ 4 \end{bmatrix} + \begin{bmatrix} 0.40 \\ 0.55 \end{bmatrix} (0.52 - 0.49) = \begin{bmatrix} 2.51 \\ 4.02 \end{bmatrix}$$

$$\hat{P}_1 = (1 - k_1 H_1) \check{P}_1 = \begin{bmatrix} 0.36 & 0.50 \\ 0.50 & 1.1 \end{bmatrix}$$

< The Error-state Extended Kalman Filter 7/15 >

$$\mathbf{x} = \hat{\mathbf{x}} + \delta \mathbf{x}$$

True state nominal state Error state

ES EKF는 Error state에 대해서만 적용되고, nominal state은 바로잡는데 사용됨.

* Linearized motion model

$$\mathbf{x}_k = f_{k-1}(\hat{\mathbf{x}}_{k-1}, u_{k-1}, 0) + F_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + L_{k-1}W_{k-1}$$

$$\mathbf{x}_k - f_{k-1}(\hat{\mathbf{x}}_{k-1}, u_{k-1}, 0) = F_{k-1}(\mathbf{x}_{k-1} - \hat{\mathbf{x}}_{k-1}) + L_{k-1}W_{k-1}$$

$\delta \mathbf{x}_k$

$\delta \mathbf{x}_{k-1}$

* Linearized measurement model

$$\mathbf{y}_k = h_k(\mathbf{x}_k, 0) + H_k(\mathbf{x}_k - \hat{\mathbf{x}}_k) + M_kV_k$$

$\delta \mathbf{x}_k$

* Why use the ES-EKF

1) Better performance

비선형 nominal state를 계속 알고 대입하는 것보다 'small' error state를 계산하는 것이 더 효율이 좋음. linearization error가 누적적으로 작아져 더 정확하다.

2) constrained quantities (ex. rotation) 에 대해 더 잘 작동.

[Loop]

- ① Update nominal state with motion model

$$\check{\mathbf{x}}_k = f_{k-1}(\check{\mathbf{x}}_{k-1}, \mathbf{u}_{k-1}, 0)$$

$\check{\mathbf{x}}_{k-1}$ or $\check{\mathbf{x}}_{k-1}$: 측정을 하기 전에 nominal state가 업데이트된 것

If a measurement
is unavailable

있으므로 $\check{\mathbf{x}}_{k-1}$ 은 가능하다.

- ② propagate uncertainty

$$\check{\mathbf{P}}_k = F_{k-1} \check{\mathbf{P}}_{k-1} F_{k-1}^T + L_{k-1} Q_{k-1} L_{k-1}^T$$

$\hat{\mathbf{P}}_{k-1}$ or $\check{\mathbf{P}}_{k-1}$

- ③ If a measurement is available

- 1) Compute Kalman Gain

$$\mathbf{K}_k = \check{\mathbf{P}}_k \mathbf{H}_k^T (\mathbf{H}_k \check{\mathbf{P}}_k \mathbf{H}_k^T + \mathbf{R})^{-1}$$

- 2) Compute error state

$$\delta \hat{\mathbf{x}}_k = \mathbf{K}_k (\mathbf{y}_k - h_k(\check{\mathbf{x}}_k, 0))$$

- 3) correct nominal state


$$\hat{\mathbf{x}}_k = \check{\mathbf{x}}_k + \delta \hat{\mathbf{x}}_k$$

- 4) correct state covariance

$$\hat{\mathbf{P}}_k = (I - \mathbf{K}_k \mathbf{H}_k) \check{\mathbf{P}}_k$$

< Limitations of the EKF 7/15 >

EKF는 비선형 motion model과 measurement model을 선형화시켜 mean과 covariance를 업데이트하면서 작동한다. 원본인 nonlinear function과 선형화시킨 linear approximation 사이의 차를 linearization error라고 부른다.



$$f(x) \approx f(a) + \left. \frac{\partial f(x)}{\partial x} \right|_{x=a} (x-a) \text{ 에서.}$$

f(x)가 얼마나 비선형적인지.

How far away from the operating point the linear approximation is being used

이 따라서 linearization error가 달라짐

* The EKF is prone to linearization error when

① The system dynamics are highly nonlinear

② system이 evolving 하는 속도에 비해 sensor sampling time이
느린 경우

↓
이에 따라.

① Estimated mean state가 정확이랑 크게 달라질 수 있다

② Estimated covariance state도 부정확해 정확한 uncertainty를
계산해낼 수 없다

* Practice 과정에서 computing Jacobians가 큰 문제가 될 수 있음.

특히 복잡한 nonlinear system의 경우

Analytical differentiation은 human error로 인해

numerical differentiation은 slow & unstable

Automatic differentiation은 can behave
unpredictably

⊕

예전에 이분 불가능한 system을 다룰 수 있다.
(step function)

→ Kalman filtering에 꼭 linearization이 필요한가?