

< Finite-horizon LQR 8/9 >

Linear time-invariant (LTI) state-space equation:

$$\dot{x} = Ax + Bu$$

finite cost function 은 다음과 같다.

$$J = h(x(t_f)) + \int_0^{t_f} \ell(x(t), u(t)) dt$$

$$h(x) = x^T Q_f x, \quad Q_f = Q_f^T \succeq 0$$

$$\ell(x, u) = x^T Q x + u^T R u, \quad Q = Q^T \succeq 0, \quad R = R^T \succ 0.$$

[정리]

$$\textcircled{1} h(x(t_f)) = x^T Q_f x$$

: 마지막 상태 ($t = t_f$)에서의 cost. 마지막에 x 가 0이 아니라면 cost가 발생

$$\textcircled{2} \int_0^{t_f} (x^T Q x + u^T R u) dt$$

: 제어하는 전체 과정에서 발생한 비용.

여기서 Q, R, Q_f 는 고정된 행렬. Q_f 는 $t = t_f$ 의 때의 Q 가 보다 최종 상태가 목표와 떨어져 있을 때 어느 정도의 가중치를 부여해 cost에 더할지 결정하는 행렬

HJB는 다음과 같다

$$0 = \min_u \left[x^T Q x + u^T R u + \frac{\partial J^*}{\partial x} (Ax + Bu) + \frac{\partial J^*}{\partial t} \right]$$

[정리]

optimal cost-to-go, J^* 는 지금 dt 동안 지불하는 비용 + dt 이후부터 지불하는 비용임.

$$J^*(x, t) = \min_u \left[(x^T Q x + u^T R u) dt + J^*(x + dx, t + dt) \right]$$

$$\dot{x} = Ax + Bu \text{ 이므로 } dx = (Ax + Bu) dt$$

$J^*(x+dx, t+dt) \approx$ Taylor expansion

$$\begin{aligned} J^*(x+dx, t+dt) &\approx J^*(x, t) + \frac{\partial J^*}{\partial x} dx + \frac{\partial J^*}{\partial t} dt \\ &= J^*(x, t) + \frac{\partial J^*}{\partial x} (Ax + Bu) dt + \frac{\partial J^*}{\partial t} dt \end{aligned}$$

따라서 원래 식이

$$J^*(x, t) = \min_u \left[(x^T Q x + u^T R u) dt + J^*(x, t) + \frac{\partial J^*}{\partial x} (Ax + Bu) dt + \frac{\partial J^*}{\partial t} dt \right]$$

$$0 = \min_u \left[(x^T Q x + u^T R u) dt + \frac{\partial J^*}{\partial x} (Ax + Bu) dt + \frac{\partial J^*}{\partial t} dt \right]$$

dt로 나누면

$$0 = \min_u \left[(x^T Q x + u^T R u) + \frac{\partial J^*}{\partial x} (Ax + Bu) + \frac{\partial J^*}{\partial t} \right]$$

(32)
min 안의 식이 u 에 대한 이차식이므로 $\frac{\partial}{\partial u} = 0$ 으로 만드는 u 를 찾는다

$$\frac{\partial}{\partial u} = 2u^T R + \frac{\partial J^*}{\partial x} B = 0$$

$$u^* = \pi^*(x, t) = -\frac{1}{2} R^{-1} B^T \frac{\partial J^*}{\partial x}^T$$

cost-to-go function의 형태를 이차함수라고 가정하자

$$J^*(x, t) = x^T S(t) x, \quad S(t) = S^T(t) > 0$$

$$\frac{\partial J^*}{\partial x} = 2x^T S(t), \quad \frac{\partial J^*}{\partial t} = x^T \dot{S}(t) x \rightarrow \text{따라서}$$

$$\left\{ \begin{aligned} u^* &= \pi^*(x, t) = -R^{-1} B^T S(t) x \end{aligned} \right.$$

$$0 = x^T [Q - S(t) B R^{-1} B^T S(t) + S(t) A + A^T S(t) + \dot{S}(t)] x$$

모든 λ 에 대해 HJB를 만족하려면

$$-\dot{S}(t) = S(t)A + A^T S(t) - S(t)BR^{-1}B^T S(t) + Q$$

(continuous-time differential Riccati equation)

⊕

$$S(t_f) = Q_f$$

S 를 PP^T 로 표현해 부정성 문제 발생을 해결할 수 있다.

같은 리카티 방정식을 사용하지만 프로그램의 성능을 높이는 방법

< Local trajectory stabilization for nonlinear systems 8/10 >

Body는 아래가도록 설계한 nominal trajectory $x_0(t)$ 과 이를 유지하기 위한 $u_0(t)$ 를 가진다. 이 (x_0, u_0) 는 nonlinear dynamics $\dot{x}_0(t) = f(x_0, u_0)$ 를 만족한다.

$$\begin{cases} \bar{x}(t) = x(t) - x_0(t) \\ \bar{u}(t) = u(t) - u_0(t) \end{cases}$$

라고 적으면

$$\dot{\bar{x}} = \dot{x} - \dot{x}_0 = f(x, u) - f(x_0, u_0)$$

first-order Taylor expansion으로 정리하면

$$\dot{\bar{x}} \approx f(x_0, u_0) + \frac{\partial f(x_0, u_0)}{\partial x} (x - x_0) + \frac{\partial f(x_0, u_0)}{\partial u} (u - u_0) - f(x_0, u_0)$$

$$= A(t)\bar{x} + B(t)\bar{u}$$

$$\Rightarrow u^* = u_0(t) - K(t)(x - x_0(t))$$

[정리]

$$u^* = \underbrace{u_0(t)}_{\text{nominal feedforward}} - \underbrace{K(t)(x - x_0)}_{\text{feedback correction}}$$

nominal

feedforward

feedback

correction

: 궤적에서 벗어났을 때 되돌리는 입력

$\bar{x}^T Q \bar{x}$ 와 $\bar{u}^T R \bar{u}$ 가 복잡하게 작용해 cost가 최소화되는 방법을 찾는다. 예를 들어 $x_0(t)$ 에서 많이 벗어난 상황이라면 u_0 에 추가 feedback을 더한 제어를 사용하는 것이 제트 u_0 를 써서 $\bar{x}^T Q \bar{x}$ cost를 늘리는 것보다 cost가 적을 것 같고 판단할 수 있다.

< Linear Quadratic optimal tracking 8/10 >

전에는 $x=0$ 으로 만드는 것을 목표로 했다면 이제는 원하는 목표 $x_d(t_f)$ 로 둔다.

$$\dot{x} = Ax + Bu$$

$$h(x) = (x - x_d(t_f))^T Q_f (x - x_d(t_f)) \quad Q_f = Q_f^T \geq 0$$

$$J(x, u, t) = (x - x_d(t))^T Q (x - x_d(t)) + (u - u_d(t))^T R (u - u_d(t)) \quad \begin{cases} Q = Q^T \geq 0 \\ R = R^T \geq 0 \end{cases}$$

cost를 전개해보면

$$(x - x_d)^T Q (x - x_d) = x^T Q x - 2x_d^T Q x + x_d^T Q x_d$$

목표가 $x_d(t) \neq 0$ 이므로 $J^* = x^T S x$ 처럼 들을 수 없다. 따라서 더욱 일반적으로 쓴다.

$$J^*(x, t) = x^T S_{xx}(t) x + 2x^T S_x(t) + S_0(t)$$

$$\frac{\partial J^*}{\partial x} = 2x^T S_{xx}(t) + 2S_x^T(t)$$

$$\frac{\partial J^*}{\partial t} = x^T \dot{S}_{xx}(t) x + 2x^T \dot{S}_x(t) + \dot{S}_0(t)$$

HJB를 사용해 u^* 를 구하면 다음과 같다

$$0 = \min_u \left[(x - x_d(t))^T Q (x - x_d(t)) + (u - u_d(t))^T R (u - u_d(t)) + \frac{\partial J^*}{\partial x} (Ax + Bu) + \frac{\partial J^*}{\partial t} \right]$$

$$\frac{\partial}{\partial u} = 2(u - u_d(t))^T R + (2x^T S_{xx}(t) + 2S_x^T(t)) B = 0$$

$$u^*(t) = u_d(t) - R^{-1} B^T [S_{xx}(t) x + S_x(t)]$$



[정제]

① $J^*(x, t)$ 를 가리키는 cost-to-go function과 Value function은 같은 말이다

② 일반 cost J 는 $h(x(t_f)) + \int_t^{t_f} l(x, u, t) dt$ 에서 현재의 x, t 에 대해
임의의 u 에 대해 총 비용이 얼마인지를 나타낸다.

u 중에서 J 를 가장 작게 만드는 u 가 optimal $u(u^*)$ 이고, 그때의 J 가
optimal $J(J^*)$ 이다.

이제 u^* 와 J^* 를 찾기 위해 Bellman principle을 사용한다. 그러면

$$J^*(x, t) = \min_u [l(x, u, t) dt + J^*(x + f(x, u) dt, t + dt)]$$

이것의 의미는 J^* 를 현재 dt 동안의 cost와 미래의 dt 이후 J^* 의 합으로 나누어 보겠다는
것이다.

$$u^* \text{의 식을 정리하면 } 0 = \min_u \left[l(x, u, t) + \frac{\partial J^*}{\partial x} f(x, u) + \frac{\partial J^*}{\partial t} \right] \text{ HJB가 나온다.}$$

여기서 u^*, J^* 식을 구할 수 있다.

J 를 최소화하는 u^* 와 HJB의 결과 u^* 는 동일하다.

$$u^* = u_d - R^{-1} B^T (S_{xx} x + S_x) \text{ 를 변형하면 } \dots (S_{xx} \text{를 간단히 } S, S_x \text{를 } s)$$

$$u^* - u_d = -R^{-1} B^T (S_x + s)$$

$$(u^* - u_d)^T R (u^* - u_d) = (S_x + s)^T B R^{-1} B^T (S_x + s)$$

↓

$$0 = x^T [\dots] x + 2x^T [\dots] + [\dots] \text{ 식의 형태로 나오게 된다.}$$

또는 x 에 대해 상미분해야 하므로 이차, 일차, 상수 계수가 모두 0

↓

S_{xx}, S_x, S_0 은 모두 t 에 대한 함수

① Quadratic 항

$$\dot{S} + Q + SA + A^T S - SBR^{-1}B^T S = 0$$

$$\rightarrow -\dot{S}_{xx} = Q - S_{xx}BR^{-1}B^T S_{xx} + S_{xx}A + A^T S_{xx}$$

② Linear 항

$$-\dot{S}_x = -Qx_d + (A^T - S_{xx}BR^{-1}B^T)S_x + S_{xx}B u_d$$

③ constant 항

$$-\dot{S}_0 = x_d^T Q x_d - S_x^T BR^{-1}B^T S_x + 2S_x^T B u_d$$

①에는 S_{xx} 만 존재, ②에는 S_x 와 S_{xx} 공존, ③에는 S_0, S_x 가 공존한다. 따라서 S_{xx}, S_x, S_0 를 모두 계산하려면 ① → ② → ③ 순으로 순차적으로 방정식을 풀어야 한다.

$U^* = U_d - R^{-1}B^T (S_{xx}x + S_x)$ 로 S_0 까지 안가도 계산할 수 있다.

* Terminal cost

$$h(x) = (x - x_d(t_f))^T Q_f (x - x_d(t_f))$$

$$= x^T Q_f x - 2x^T Q_f x_d(t_f) + x_d(t_f)^T Q_f x_d(t_f) \quad \text{이것라}$$

$J^*(x, t_f) = x^T S_{xx}(t_f)x + 2x^T S_x(t_f) + S_0(t_f)$ 가 같아야 한다. 적분 항이 이미 우변에 있다.

→ 계수 비교를 통해

$$\left\{ \begin{array}{l} S_{xx}(t_f) = Q_f \\ S_x(t_f) = -Q_f x_d(t_f) \\ S_0(t_f) = x_d(t_f)^T Q_f x_d(t_f) \end{array} \right.$$

< pendulum exercise 8/17 >

$$m l^2 \ddot{\theta} + m g l \sin \theta = Q = u$$

$$x_1 = \theta, x_2 = \dot{\theta}$$

$$\begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix} = \begin{bmatrix} x_2 \\ \frac{1}{m l^2} (u - m g l \sin \theta) \end{bmatrix}$$

$$= \begin{bmatrix} x_2 \\ -\frac{g}{l} \sin x_1 + \frac{1}{m l^2} u \end{bmatrix} = A x_0 + B u =$$

$$-\frac{g}{l} \cos(x_1)$$

$$= \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} + \begin{bmatrix} 0 \\ \frac{1}{m l^2} \end{bmatrix} u$$

x_1

$$x_d = (0.3) \sin(t) \text{ 라 } \dot{x}_d$$

$$x_d(t) = (0.3) \sin(t) \rightarrow \theta$$

$$\dot{x}_d = (0.3) \cos(t)$$

$$u_d(t) = m l^2 (-0.3 \sin(t)) + m g l \sin(\sin(t))$$

x_2

< optimal tracking tests 8/17 >

$$\begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix} x + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u = \dot{x} = \begin{bmatrix} \dot{x}_1 \\ \dot{x}_2 \end{bmatrix}$$

$$\dot{x}_1 = x_2$$

$$x_1 = p, x_2 = v$$

가속도 일정

$$\dot{x}_2 = u$$

b

$$u = a \text{ (가속도)}$$

$$x_1 = \frac{1}{3} t^3 + 4 t^2 + 5 t + b$$

$$x_2 = t^2 + 8 t + 5$$

$$u = 2 t + 8$$

$$\begin{bmatrix} 1 & 0 \end{bmatrix}$$

$$y = \begin{bmatrix} 1 & 0 \end{bmatrix} x + \begin{bmatrix} 0 \\ 1 \end{bmatrix} u$$

position

GPS

$$x_{k+1} = (x + dt \cdot v)$$

$$v_{k+1} =$$